

Ejemplo con 4 estados en notación Sutton & Barto: sistema lineal y solución por punto fijo

1 El MDP en notación Sutton & Barto

En Sutton & Barto, la dinámica se da como la distribución conjunta

$$p(s', r \mid s, a) = \Pr\{S_{t+1} = s', R_{t+1} = r \mid S_t = s, A_t = a\}.$$

Consideremos $\mathcal{S} = \{s_1, s_2, s_3, s_4\}$, $\mathcal{A} = \{a_1, a_2\}$, política fija

$$\pi(a_1 \mid s) = 0.7, \quad \pi(a_2 \mid s) = 0.3 \quad \text{para todo } s,$$

y factor de descuento $\gamma = 0.9$. Las recompensas son deterministas dadas (s, a, s') .

Tabla de $p(s', r \mid s, a)$.

s	a	s'	r	$p(s', r \mid s, a)$
s_1	a_1	s_2	1	0.8
s_1	a_1	s_3	0	0.2
s_1	a_2	s_1	2	0.1
s_1	a_2	s_4	1	0.9
s_2	a_1	s_3	1	1.0
s_2	a_2	s_1	0	0.5
s_2	a_2	s_3	2	0.5
s_3	a_1	s_4	1	1.0
s_3	a_2	s_2	3	1.0
s_4	a_1	s_1	0	1.0
s_4	a_2	s_2	1	1.0

2 La ecuación de Bellman en forma Sutton & Barto

$$v_\pi(s) = \sum_a \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_\pi(s')].$$

3 Cálculo término por término

Para s_1 .

$$v_\pi(s_1) = 0.7(0.8[1 + 0.9 v_\pi(s_2)] + 0.2[0 + 0.9 v_\pi(s_3)]) + 0.3(0.1[2 + 0.9 v_\pi(s_1)] + 0.9[1 + 0.9 v_\pi(s_4)]).$$

Para s_2 .

$$v_\pi(s_2) = 0.7 \cdot 1.0[1 + 0.9 v_\pi(s_3)] + 0.3(0.5[0 + 0.9 v_\pi(s_1)] + 0.5[2 + 0.9 v_\pi(s_3)]).$$

Para s_3 .

$$v_\pi(s_3) = 0.7 \cdot 1.0[1 + 0.9 v_\pi(s_4)] + 0.3 \cdot 1.0[3 + 0.9 v_\pi(s_2)].$$

Para s_4 .

$$v_\pi(s_4) = 0.7 \cdot 1.0[0 + 0.9 v_\pi(s_1)] + 0.3 \cdot 1.0[1 + 0.9 v_\pi(s_2)].$$

4 El sistema lineal explícito

Con $v_i \equiv v_\pi(s_i)$:

$$\begin{cases} 0.973 v_1 - 0.504 v_2 - 0.126 v_3 - 0.243 v_4 = 0.89 \\ -0.135 v_1 + v_2 - 0.765 v_3 = 1.0 \\ -0.27 v_2 + v_3 - 0.63 v_4 = 1.6 \\ -0.63 v_1 - 0.27 v_2 + v_4 = 0.3 \end{cases}$$

En forma matricial:

$$(I - \gamma P_\pi) v_\pi = \bar{R}_\pi,$$

con

$$\bar{R}_\pi = \begin{pmatrix} 0.89 \\ 1.0 \\ 1.6 \\ 0.3 \end{pmatrix}, \quad P_\pi = \begin{pmatrix} 0.03 & 0.56 & 0.14 & 0.27 \\ 0.15 & 0 & 0.85 & 0 \\ 0 & 0.3 & 0 & 0.7 \\ 0.7 & 0.3 & 0 & 0 \end{pmatrix}.$$

5 La solución por punto fijo

5.1 El operador de Bellman

$$(\mathcal{T}_\pi v)(s) = \sum_a \pi(a | s) \sum_{s', r} p(s', r | s, a) [r + \gamma v(s')].$$

La ecuación de Bellman es $v_\pi = \mathcal{T}_\pi v_\pi$, es decir, v_π es punto fijo de $\mathcal{T}_\pi$.

5.2 El operador es una contracción

Theorem 1. Para cualesquiera $u, v \in \mathbb{R}^4$,

$$\|\mathcal{T}_\pi u - \mathcal{T}_\pi v\|_\infty \leq \gamma \|u - v\|_\infty = 0.9 \|u - v\|_\infty.$$

Proof. Para cualquier s ,

$$|(\mathcal{T}_\pi u)(s) - (\mathcal{T}_\pi v)(s)| \leq \gamma \sum_a \pi(a | s) \sum_{s', r} p(s', r | s, a) |u(s') - v(s')| \leq \gamma \|u - v\|_\infty.$$

Tomando el máximo sobre s se obtiene el resultado. □

5.3 Consecuencias (teorema de Banach)

Como $\mathcal{T}_\pi$ es una contracción con factor $\gamma = 0.9 < 1$ en el espacio completo $(\mathbb{R}^4, \|\cdot\|_\infty)$:

1. Existe un único $v_\pi \in \mathbb{R}^4$ tal que $\mathcal{T}_\pi v_\pi = v_\pi$.
2. Para cualquier v_0 , la sucesión $v_{k+1} = \mathcal{T}_\pi v_k$ converge a v_π .
3. $\|v_k - v_\pi\|_\infty \leq 0.9^k \|v_0 - v_\pi\|_\infty$.
4. $\|v_{k+1} - v_\pi\|_\infty \leq 9 \|v_{k+1} - v_k\|_\infty$.

5.4 Iteración explícita

Empezando con $v_0 = (0, 0, 0, 0)$:

$$\begin{aligned}v_1 &= \bar{R}_\pi = (0.89, 1.0, 1.6, 0.3), \\v_2 &= (1.6925, 2.344, 2.059, 1.1307), \\v_3 &= (2.651, \dots).\end{aligned}$$

La sucesión converge geoméricamente a v_π .

5.5 ¿Por qué el punto fijo es la solución del sistema lineal?

La ecuación $v_\pi = \mathcal{T}_\pi v_\pi$ es equivalente a

$$v_\pi = \bar{R}_\pi + \gamma P_\pi v_\pi \iff (I - \gamma P_\pi)v_\pi = \bar{R}_\pi.$$

El punto fijo de $\mathcal{T}_\pi$ es exactamente la solución de este sistema lineal. Por Banach, existe, es única, y se calcula iterando.

5.6 ¿Por qué el sistema tiene solución única?

P_π es estocástica, así que sus autovalores tienen módulo ≤ 1 . Por tanto, γP_π tiene autovalores de módulo $\leq 0.9 < 1$, y $I - \gamma P_\pi$ es invertible. Luego

$$v_\pi = (I - \gamma P_\pi)^{-1} \bar{R}_\pi.$$