

Ecuaciones de Optimalidad de Bellman

1 Idea central

Bajo una política fija π , la marginalización del modelo gráfico del MDP da las ecuaciones de evaluación:

$$v_\pi(s) = \sum_a \pi(a \mid s) \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v_\pi(s')],$$
$$q_\pi(s, a) = \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v_\pi(s')].$$

Las **ecuaciones de optimalidad de Bellman** describen el caso en que la política se elige para maximizar el valor. La política óptima π_* es determinista y greedy respecto a q_* :

$$\pi_*(a \mid s) = \begin{cases} 1, & a = \arg \max_{a'} q_*(s, a'), \\ 0, & \text{en otro caso.} \end{cases}$$

Las funciones de valor óptimas son

$$v_*(s) = \max_{\pi} v_\pi(s), \quad q_*(s, a) = \max_{\pi} q_\pi(s, a).$$

2 Ecuación de optimalidad para v_*

Por el principio de optimalidad, la primera acción se elige para maximizar y a partir de $t + 1$ se sigue la política óptima:

$$v_*(s) = \max_a \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v_*(s')].$$

Definiendo el operador de optimalidad $\mathcal{T}_*$ por

$$(\mathcal{T}_* v)(s) = \max_a \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v(s')],$$

la ecuación anterior dice que v_* es punto fijo: $v_* = \mathcal{T}_* v_*$.

3 Ecuación de optimalidad para q_*

Condicionando en $(S_t = s, A_t = a)$ y maximizando sólo a partir de $t + 1$:

$$q_*(s, a) = \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma \max_{a'} q_*(s', a')].$$

Equivalentemente, usando $v_*(s') = \max_{a'} q_*(s', a')$:

$$q_*(s, a) = \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v_*(s')].$$

4 Relaciones entre v_* y q_*

Marginalizando la acción óptima:

$$v_*(s) = \max_a q_*(s, a),$$

$$q_*(s, a) = \sum_{s'} p(s' | s, a) [\bar{R}(s, a, s') + \gamma v_*(s')].$$

Sustituyendo una en la otra se obtienen las dos formas equivalentes de la ecuación de optimalidad.

5 Comparación con evaluación de política

	Evaluación (π fija)	Optimalidad (π_*)
v	$v_\pi(s) = \sum_a \pi(a s) \sum_{s'} p(s' s, a) [\bar{R} + \gamma v_\pi(s')]$	$v_*(s) = \max_a \sum_{s'} p(s' s, a) [\bar{R} + \gamma v_*(s')]$
q	$q_\pi(s, a) = \sum_{s'} p(s' s, a) [\bar{R} + \gamma v_\pi(s')]$	$q_*(s, a) = \sum_{s'} p(s' s, a) [\bar{R} + \gamma \max_{a'} q_*(s', a')]$
Acción	promediada con π	maximizada con $\max$
Operador	lineal $\mathcal{T}_\pi$	no lineal $\mathcal{T}_*$
Punto fijo	$v_\pi = \mathcal{T}_\pi v_\pi$	$v_* = \mathcal{T}_* v_*$

Observación sobre la marginalización

En la derivación por marginalización, la diferencia entre evaluación y optimalidad es únicamente cómo se trata la acción A_t :

- En evaluación, A_t se marginaliza con $\pi(\cdot | s)$: aparece $\sum_a \pi(a | s)$.
- En optimalidad, A_t se elige con $\max_a$: aparece $\max_a$.

El resto de la cadena (transiciones $p(s' | s, a)$, recompensas $\bar{R}(s, a, s')$ con sus tres argumentos, y el factor γ) es idéntico en ambos casos.