

Aclaración: por qué la ecuación de Bellman se ve distinta en Sutton & Barto y en la derivación por marginalización

1 Dos formas de escribir la misma ecuación

En Sutton & Barto (S&B) la ecuación de Bellman para v_π es

$$v_\pi(s) = \sum_a \pi(a | s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_\pi(s')].$$

En nuestra derivación por marginalización es

$$v_\pi(s) = \sum_a \pi(a | s) \sum_{s'} p(s' | s, a) [\bar{R}(s, a, s') + \gamma v_\pi(s')].$$

No son inconsistentes: son la misma ecuación escrita con dos descomposiciones distintas de la conjunta.

2 Dos formas de factorizar la misma conjunta

En S&B, la dinámica se da como la conjunta sobre el siguiente estado y la recompensa:

$$p(s', r | s, a) = \Pr\{S_{t+1} = s', R_{t+1} = r | S_t = s, A_t = a\}.$$

En nuestra derivación, la factorizamos en dos pasos:

$$p(s', r | s, a) = p(s' | s, a) p(r | s, a, s').$$

S&B	Nuestra derivación
$p(s', r s, a)$	$p(s' s, a) \cdot p(r s, a, s')$
Una sola distribución conjunta sobre (s', r)	Transición $p(s' s, a)$ y recompensa condicional $p(r s, a, s')$
Se marginaliza r dentro de la suma	Se define $\bar{R}(s, a, s') = \sum_r r p(r s, a, s')$ y se marginaliza r primero

3 Cómo se pasa de una a otra

Partimos de la forma S&B:

$$v_\pi(s) = \sum_a \pi(a | s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_\pi(s')].$$

Paso 1: factorizar la conjunta.

$$p(s', r | s, a) = p(s' | s, a) p(r | s, a, s').$$

Sustituyendo,

$$v_\pi(s) = \sum_a \pi(a | s) \sum_{s', r} p(s' | s, a) p(r | s, a, s') [r + \gamma v_\pi(s')].$$

Paso 2: separar los dos términos dentro del corchete.

$$v_\pi(s) = \sum_a \pi(a | s) \sum_{s'} p(s' | s, a) \left[\sum_r r p(r | s, a, s') + \gamma v_\pi(s') \sum_r p(r | s, a, s') \right].$$

Paso 3: usar la normalización.

$$\sum_r p(r \mid s, a, s') = 1.$$

Paso 4: definir la recompensa media.

$$\bar{R}(s, a, s') = \sum_r r p(r \mid s, a, s').$$

Sustituyendo,

$$v_\pi(s) = \sum_a \pi(a \mid s) \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v_\pi(s')].$$

Esta es exactamente nuestra forma.

4 Por qué en S&B no aparece $\bar{R}(s, a, s')$

En S&B no se introduce $\bar{R}(s, a, s')$ porque mantienen la suma sobre r explícita. La razón es pedagógica: en S&B la recompensa es parte de la dinámica y se prefiere no marginalizarla antes de tiempo. En nuestra derivación, marginalizamos r desde el principio porque queríamos aislar la estructura de la cadena de estados y acciones. Es una elección de presentación, no una diferencia matemática.

5 La conexión explícita

S&B	Nuestra derivación
$\sum_{s',r} p(s', r \mid s, a) [r + \gamma v_\pi(s')]$	$\sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v_\pi(s')]$
Se suma sobre r y s' simultáneamente	Se suma primero sobre r (definiendo $\bar{R}$) y luego sobre s'
La recompensa esperada se calcula dentro de la suma	La recompensa esperada se calcula antes (en $\bar{R}$)

6 Lo mismo para q_π y las ecuaciones de optimalidad

q_π en S&B:

$$q_\pi(s, a) = \sum_{s',r} p(s', r \mid s, a) [r + \gamma v_\pi(s')].$$

q_π en nuestra forma:

$$q_\pi(s, a) = \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v_\pi(s')].$$

Optimalidad en S&B:

$$v_*(s) = \max_a \sum_{s',r} p(s', r \mid s, a) [r + \gamma v_*(s')],$$

$$q_*(s, a) = \sum_{s',r} p(s', r \mid s, a) \left[r + \gamma \max_{a'} q_*(s', a') \right].$$

Optimalidad en nuestra forma:

$$v_*(s) = \max_a \sum_{s'} p(s' \mid s, a) [\bar{R}(s, a, s') + \gamma v_*(s')],$$

$$q_*(s, a) = \sum_{s'} p(s' \mid s, a) \left[\bar{R}(s, a, s') + \gamma \max_{a'} q_*(s', a') \right].$$

7 ¿Cuál usar?

Situación	Forma recomendada
Se conoce $p(s', r \mid s, a)$ directamente (S&B)	Forma S&B
Se conoce $p(s' \mid s, a)$ y $p(r \mid s, a, s')$ por separado	Nuestra forma
Se quiere derivar por marginalización de la cadena	Nuestra forma
Se quiere comparar con la literatura de RL	Forma S&B
Se quiere simplificar el álgebra	Nuestra forma (una suma menos)